

Compactação Trivial

Economizar espaço (virtual ou real) muitas vezes é importante. Usar menos espaço é mais eficiente, e é possível economizar dinheiro. Se você estivesse alugando um apartamento que fosse maior do que o necessário para suas coisas e a sua família, seria possível fazer um “downsize” para um lugar menor, mais barato. Se você paga por byte para armazenar seus dados em um servidor, talvez queira compactá-los para que a armazenagem tenha um custo menor. A compactação é o ato de tomar os dados e codificá-los (modificar o seu formato) de modo que ocupem menos espaço. A descompactação é o processo inverso, que faz com que os dados retornem ao seu formato original.

Considere os nucleotídeos que formam um gene no DNA. Cada nucleotídeo pode assumir apenas um entre quatro valores: A, C, G ou T. No entanto, se o gene for armazenado como uma string, que pode ser imaginada como uma coleção de caracteres Unicode, cada nucleotídeo será representado por um caractere, o qual, em geral, exige 8 bits para armazenagem. Em binário, apenas 2 bits são necessários para armazenar um tipo com quatro valores possíveis: 00, 01, 10 e 11 são os quatro valores diferentes que podem ser representados por 2 bits. Se atribuirmos o valor 00 a A, 01 a C, 10 a G e 11 a T, a área de armazenagem necessária para uma string de nucleotídeos poderá ser reduzida em 75% (de 8 bits para 2 bits por nucleotídeo).

Compactar a sequência de um gene:

"TAGGGATTAAACCGTTATATATATAGCCATGGATCGATTATAGGGATTAACCGTTATATATAGCCATGG
ATCGATTATA"

ACGT -> 32bits


ACGT -> 8bits

2Bits: 00, 01, 10, 11 -> 2^2 -> 4

ABCDEFGH -> 64 bits

ABCDEFGH -> 24 bits

3Bits: 000,001,010,011,100,101,110,111 ->2^3 -> 8



Livro: Kopec, David. Problemas Clássicos de Ciência da Computação com Python (p. 36). Novatec Editora. Kindle Edition.

Sequência de um vírus:

ACCGCGCTTCTTCTCGAGGGCCCGTAGGGACCGAGCGCTTGATTAAAGCCTGGTCTGCTT
GTATGATTATCTAACAGAGCCCCTAAAGAAACCAGTCCGGACTATAATTGCCTAACAGTGC
GATTCAATTGATCCACAGAACGCCCTGTATTATCAGCCGCGGGTACCCACAGCAGCTCCGACATCCG
GAGGAGTGCCGTGGAGTCGCTAGGCAGGGTAGCTATTTGAGCTTGTTGCATTGATTGCTTTACCT
GCTTACCTTGGGTGCTGAGAGACCTTATCTAGTTCTGAAGGCTCGACAAGGCAGATCCACGGAGGA
GCTGATATTGGTGGACAAGCTGTGGATAGGGAGCAACCCCTATCCCTAATCTACCTCACCAAGTCAG
GGCAATCCGGGCCATTGTTCCAGGCACGGATAAGCAATGCCATGTCCACGTCCAAGAGGAAGCG
GGGAGATGATTGAATTGGAATAAGCGGGCCTAAGAAGAAGGCATCTCAGCTGGCTGAAGAGGG
CTGGAAGCAAGGCGATAGGCCATCCCTCAAATCCAGACACTCCAGCATGCTGGACCACCATGATAA
CTGTCCCCTCGGAGGAGTATGTGACCTCATCAACACCTATGCCGAGGATCTGACGAGGGCAACCGCC
ACACCGCGAGACTCTGACGTACAAGATGCCGTCGACTACCACTCGTGGCGACGCCGCTGCCG
CTACTCCAACACCGGAACCGGTGTAATGTGGCTGGTGTATGACACCACTCCGGCGACAAGCTCCGACC
CCGCAAACCTATTTGCTTACCGTACACGCTAAAAGCGTGGCCGGCACATGGAAAGTGAGCCGGAG
CTGTGTCATCGCTTCTCGTGGTAAACGGCGATGGTTTCAACATGGAGACCGACGGTCGGATTGGTCG
GATATCCCTCCCTCGAATACAAGTTGAAGCCTGCAAGCGAACATCTACTTCCACAAGTTCACGAGTG
GGTGGGAGTGAGAACGCAGTGGAGAATGTAACGGACGGAGGAGTTGGGCCATCCAGAGAGGAGC

TCTGTACATGGTCATTGCCCAAGGCAATGGCCTACTTTACTGCCATGGCAGACCGTCTGTACTTA
AGAGTGTGGCAACCAGTAATGAATAAAACTCCGTTTATTATTTGATGAATGCTGAAAGCTTACAT
TAATATGTCGTGCGATGGCACGAAAAAACACGCAAACAATACAGGGGGTAGTCGGCGGGCGCTA
AGGGTGGTGCCTGGCGAGAACATCGAAAATCAAGATCTATATGAATTACACTCCTCCGTAGGAG
GAAGCACAGGGGGAGAATACCACTCTCCCCGGCGACATAATGTAATGACGCAGTTGCCTCGAAAT
ACTCCAGCTGCCCTGGAGTCATTCCTCATCCAATCTCATCCGAGTTGGCGAGGATTATTGTAGGCTT
GACTTCTCTGCACCTTTCTTACCATACTGGGGTTACAATGAAATCCCTTGACAGCCAACTAAC
TGTTCCAACAAGGACAGAACGAAATTAAACGGAATATCATCTACGATGTTAGATTGCCTCGTTATGA
AGACCAATCAACATTATTGCGAGTAATTATGAACCCCTAGGCTCTGGCCAAGTAGATTTCGGGTT
TTGGTGGGCCGACGATGAGGGCTCTGCTTCTGATCTTCTGATGACTGGATACAGAACATCCATCC
ATTGGAGGTAGAAATTGCATCCTCGAGGGTATAACAGGTAGGTTGAAGGAGCATGTAAGCTCGGGAC
TAACCTGGAAGATGTTAGGCTGGAGCCAATCGTTGATTGACTCATTACAAAGTAAATCAGGTGAGGAGG
GTGGATGAGGATTGGTAACCTCTCTGAATCTCAGGAAAAAGCTTATTGAGAGTATTCAAATACTG
CAATTGTGGACCAATCAAAGGGAGCTCTGGATCATGGAGAGGTACTCTCTTGAGGTAGCG
TGTGAAATAATGTCGCAATTTCATCTTAGAAGGCTTTCTTACCTCTGAATCAGATTTCCTA
GGAAGGGGACTCCTAGGAATGAAAGTACCTCTCAAACACAGCCAGAGGTTCTGAGAATGTAAT
CCCTCACTCTGTTAAGTACTGGCACTCTGAATATTGGTGAACCCATTATCAAAGAACCTTGAG
TCAGATATCCTTATCGGCTCTGGCTGAAGCAATGCAATGCAAACCTCCATCTTATGTGCCTCT
CGGGCACATAGAATATTTGGGATCCAACGAAACGACGAGCTCCAGATCATGACAGGCAGATTCA
GGATTTCTGGACACTTGGATAGGTTAGGAACGTTAGCGTTCTGTGAGAACTGACGGTTGGATG
AGGAGGAGGCCATAGCCGACGACGGAGGTTGAGGCTGAGGGATGGCAGACTGGAGCTCAAACCT
ATAGTATACCGTGCCTCGAAATCCGCCCTCATTGTCTTATAGTGGTTGAAATGGCCGGACCG
GGCCGGCCCAGCAGGAAAAGAAGGCGCGACTAATAT